KỊCH BẢN THỰC NGHIỆM

<u>Đề tài:</u> Khai phá Dữ liệu Đa nguồn trong Quản trị Nhân sự – Dự báo Rủi ro Rời bỏ & Tối ưu hoá Lộ trình Gắn kết Nhân viên tại Tập đoàn Masan

BƯỚC 1 - DỮ LIỆU ĐA NGUỒN (Time Series)

Nhóm sử dụng 3 file dữ liệu, kết nối với nhau qua khóa Employee_ID:

- **Employee_List** (100.000 dòng): thông tin định danh, nhân khẩu học, thâm niên, đơn vị kinh doanh và nhãn mục tiêu Status (Active / Inactive). Tỷ lệ nhãn 40% Active – 60%.
- **Employee_Time_Series** (417.884 dòng, 14 cột): log hành vi theo từng tháng gồm giờ tăng ca, ngày nghỉ phép, ngày vắng mặt, điểm hiệu suất, số vi phạm kỷ luật. Đây là nguồn dữ liệu chuỗi thời gian cốt lõi.
- **Employee_Survey** (59.670 dòng, 5 cột): kết quả khảo sát định kỳ gồm điểm eNPS, hài lòng với lương, môi trường, quản lý và trường phản hồi tự do (Comment_Text) xử lý bằng NLP. Unstructured data

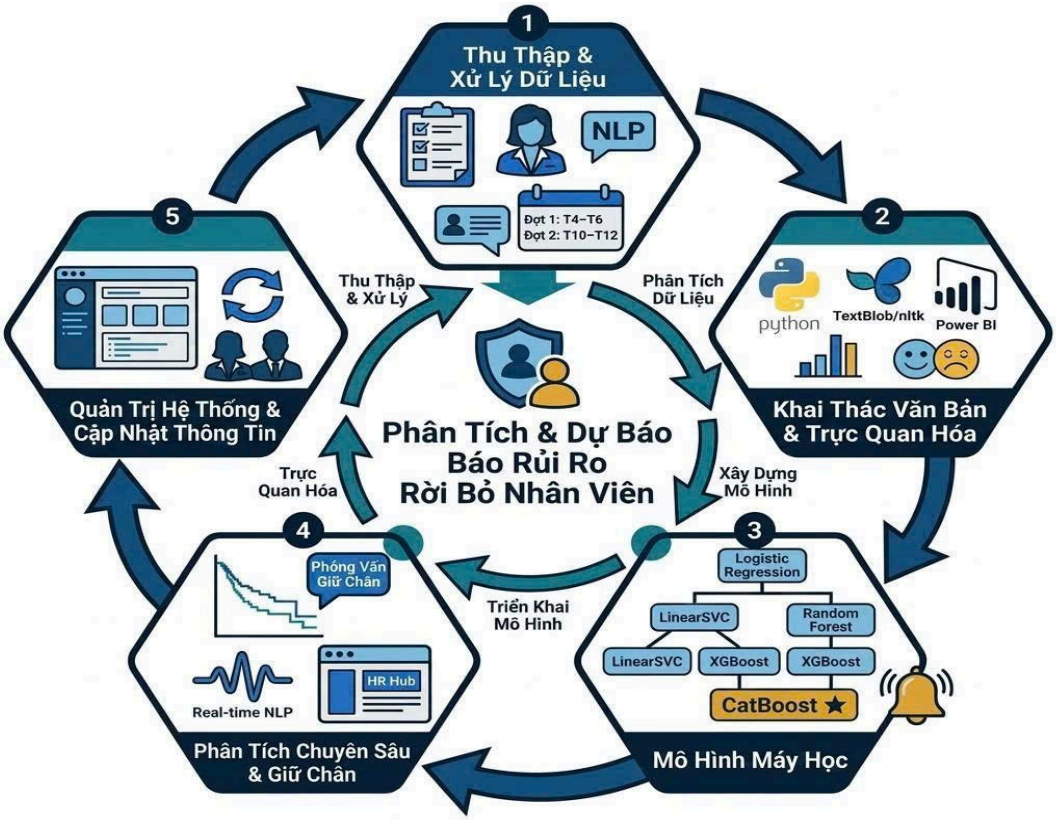

BƯỚC 2 - TIỀN XỬ LÝ & FEATURE ENGINEERING (Time Series)

Join / Merge	Xử lý khuyết	Window Features	Temporal Split
3 file → 1 master theo Employee_ID	Imputation - OutlierNLP survey text	Lag 3 / 6 tháng Rolling avg, Trend	Train → Val → Test SMOTE (train only)

- **Tích hợp dữ liệu:** Time_Series được tổng hợp theo cửa sổ 3 tháng và 6 tháng gần nhất (rolling aggregation) trước khi join vào bảng master, tránh bùng nổ số dòng.
- **Xử lý khuyết thiếu:** biến số điền bằng median theo nhóm phòng ban; biến phân loại điền bằng mode; Comment_Text trống gán nhãn no_response.
- **NLP:** Comment_Text được làm sạch → tokenize → phân tích sentiment → tạo cột Sentiment_Score (–1 đến +1) đưa vào tập đặc trưng.
- **Phân chia dữ liệu (Temporal Split):** vì là time series, không dùng random split. Chia theo thứ tự thời gian: Train (tháng 1–18) → Validation (tháng 19–21) → Test (tháng 22–24). **SMOTE chỉ áp dụng trên tập Train** để tránh data leakage.
- Feature Engineering đặc thù time series:
    - Lag features: Performance_Score_lag3, OT_Hours_lag6...
    - Rolling statistics: trung bình, tổng, độ lệch chuẩn trong cửa sổ 3 và 6 tháng
    - Trend features: hệ số góc của hiệu suất 6 tháng gần nhất (âm = đang đi xuống)
    - Interaction features: OT_eNPS_ratio (tăng ca cao + hài lòng thấp = rủi ro cao)

BƯỚC 3 - THUẬT TOÁN THỰC NGHIỆM

Thuật toán	Vai trò
Logistic Regression	Baseline, giải thích qua coef_
LinearSVC	So sánh biên phân cách
Random Forest	Ổn định, Feature Importance
XGBoost	Hiệu suất cao, xử lý missing
CatBoost	Tối ưu dữ liệu HR nhiều categorical

BƯỚC 4 - ĐỘ ĐO ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH AI

Nhóm phân loại	• **Recall** (ưu tiên nhất): tỷ lệ bắt đúng nhân viên có nguy cơ thực sự - bỏ sót là chi phí cao nhất • **F1-Score**: cân bằng Precision và Recall, phù hợp dữ liệu mất cân bằng • **AUC-ROC**: khả năng phân biệt hai lớp qua mọi ngưỡng • **AUC-PR**: đáng tin cậy hơn AUC-ROC khi nhãn mất cân bằng, tập trung vào lớp thiểu số • **Confusion Matrix**: thể hiện rõ FP và FN để phân tích loại lỗi mô hình đang mắc
Nhóm time series	• **MAE / RMSE**: đánh giá mô hình hồi quy dự báo thâm niên (`Tenure_Months`); nếu RMSE >> MAE → có sai số cực lớn cần xem lại • **MAPE**: diễn đạt sai số theo %, dễ báo cáo với lãnh đạo • **Walk-Forward Validation**: chạy vòng lặp train → test từng tháng, lấy trung bình F1/AUC, phản ánh thực tế hơn
Nhóm giải thích	• **SHAP Values**: giải thích từng dự báo cá nhân — tại sao nhân viên X được cảnh báo rủi ro cao • **Feature Importance (MDI)**: biến nào ảnh hưởng nhiều nhất toàn bộ mô hình • **Overfitting Gap**: F1(train) – F1(val) > 0.1 → cần tăng regularization

BƯỚC 5 - KẾT QUẢ DỰ KIẾN VÀ MÔ HÌNH ĐỀ XUẤT

Thuật toán	Thời gian huấn luyện	Accuracy	Precision (Lớp 1)	Recall (Lớp 1)	F1-Score (Lớp 1)
Logistic Regression	7s38	0.8086	0.82	0.87	0.85
Linear SVC	10s33	0.8108	0.82	0.88	0.85
Random Forest	13s68	0.84	0.85	0.88	0.87
XGBoost	4s	0.84	0.86	0.88	0.87
CatBoost	2ph26s	0.8418	0.86	0.88	0.87

CatBoost được chọn làm mô hình chính vì với XGBoost, SVM hay Logistic Regression: Khi người dùng nhập "Phòng Sales" trên web, model phải tải lại hàm LabelEncoder hoặc OneHotEncoder trên server để biến chữ "Sales" thành số (ví dụ: 1 hoặc [0, 1, 0, 0]) rồi mới đưa vào mô hình dự đoán được. Tuy nhiên đối với CatBoost: Nó xử lý trực tiếp dữ liệu dạng chữ (Categorical Features) bằng cơ chế Target Encoding. Người dùng chỉ cần gửi thẳng chuỗi JSON chứa chữ "Sales", "Male", "Resigned" qua API, CatBoost sẽ tự hiểu và tính toán. Hệ thống backend của hệ thống sẽ gọn gàng và ít lỗi vặt. Thêm vào đó, dữ liệu nhân sự thường sẽ có ngoại lệ, những người nhập thiếu tuổi, điền sai thâm niên, hoặc hệ thống tính sai giờ OT. Các thuật toán Logistic Regression và SVM cực kỳ nhạy cảm với các giá trị ngoại lệ (Outliers). Nếu một người có số giờ OT bị phát sinh lỗi gõ nhầm thành 500 giờ có thể làm sai lệch hoàn toàn kết quả của nhóm tuyến tính này. Random Forest và XGBoost xử lý ngoại lệ tốt hơn, nhưng XGBoost lại rất dễ bị Overfitting nếu không giám sát kỹ. Đối với CatBoost, thuật toán này được sinh ra với cơ chế chống Overfitting (tự động dừng train model khi F1-score có vấn đề). Khi đưa lên server hoạt động độc lập không có người giám sát, sự cẩn trọng này của CatBoost rất cần thiết cho hệ thống.