ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHAI PHÁ DỮ LIỆU DOANH NGHIỆP

KỊCH BẢN THỰC NGHIỆM

DỰ ĐOÁN LOẠI HỌC VIÊN DỰA TRÊN DỮ LIỆU HÀNH VI HỌC TẬP SỬ DỤNG K-MEANS - 3 NHÃN

GVHD: ThS. Nguyễn Thị Anh Thư

Lớp: DS317.Q21.VB2

Nhóm 3

Họ và tên	**MSSV**
Trần Thị Minh Hương	24540011
Bùi Hoàng Khánh Linh	24540015
Nguyễn Thanh Sơn	24540022
Huỳnh Ngọc Tài	24540023
Lê Quốc Thái	24540024

Tp. Hồ Chí Minh, 04/2026

1. GIỚI THIỆU BÀI TOÁN

Sự phát triển của các nền tảng học trực tuyến mở đại trà (MOOC) mang lại cơ hội tiếp cận giáo dục quy mô lớn nhưng đồng thời đối mặt với thách thức lớn: tỷ lệ bỏ học (dropout rate) cao do thiếu vắng sự tương tác và giám sát trực tiếp. Để giải quyết vấn đề này, việc xây dựng một hệ thống cảnh báo sớm dựa trên dữ liệu là vô cùng cấp thiết.

Bài toán cốt lõi trong khai phá dữ liệu giáo dục (Educational Data Mining - EDM) là việc định nghĩa và đo lường mức độ tương tác (engagement) của sinh viên thường mang tính chủ quan và tĩnh. Đề tài này giải quyết bài toán đó bằng cách đề xuất một kiến trúc **Hybrid Machine Learning**. Thay vì dựa vào các ngưỡng điểm cố định, hệ thống khai thác chuỗi log thời gian thực, sử dụng học không giám sát để khám phá các mẫu hành vi tự nhiên (tạo Ground Truth), sau đó sử dụng các mô hình học có giám sát tiến tiến để phân lớp và dự báo sớm nguy cơ mất động lực học tập của sinh viên.

2. PHẠM VI VÀ MỤC TIÊU NGHIÊN CỨU

- **Phạm vi nghiên cứu:**
  - Dữ liệu: Hệ sinh thái MOOCCubeX, bao gồm 5 nguồn dữ liệu dị thể (user, user-video, user-problem, comment, reply). Dữ liệu được tinh gọn thông qua quá trình tiền xử lý, tập trung phân tích tập mẫu đại diện khoảng 5.000 sinh viên.
  - Mô hình: Các thuật toán học máy cổ điển và Ensemble Learning (Logistic Regression, Random Forest, XGBoost, CatBoost).
- **Mục tiêu nghiên cứu:**
  - Xây dựng luồng dữ liệu (Data Pipeline) tự động để làm phẳng (flattening) cấu trúc JSON đa cấp và hợp nhất dữ liệu đa nguồn.
  - Triển khai thuật toán K-Means Clustering để tự động hóa quy trình gán nhãn 3 lớp (High, Medium, Low) khách quan.
  - Huấn luyện và so sánh hiệu suất của 4 mô hình học có giám sát, xử lý triệt để bài toán mất cân bằng lớp (class imbalance) bằng kỹ thuật SMOTE.
  - Trích xuất Feature Importance để xây dựng Dashboard cảnh báo sớm.

3. MỤC TIÊU THỰC NGHIỆM

- **Đánh giá chất lượng phân cụm:** Kiểm chứng độ gắn kết của các cụm hành vi được tạo ra bởi K-Means thông qua các độ đo nội tại (Silhouette Score, WSS, BSS).
- **Đánh giá khả năng dự báo chuỗi thời gian:** Xác định mô hình học có giám sát nào tối ưu nhất trong việc xử lý dữ liệu log hành vi tuần tự để dự báo nhãn tương tác.
- **Đánh giá hiệu quả của kỹ thuật cân bằng dữ liệu:** So sánh hiệu suất mô hình (đặc biệt là Recall của lớp "Low Engagement") trước và sau khi áp dụng SMOTE trên tập dữ liệu có phân bổ nhãn 4.8 : 1.8 : 3.5.

4. MÔI TRƯỜNG THỰC NGHIỆM

- Platform: Google Colab / Kaggle
- Ngôn ngữ: Python 3.14
- Thư viện chính:
  - pandas: Xử lý dữ liệu
  - numpy: Tính toán ma trận
  - matplotlib & seaborn: Trực quan hóa
  - scikit-learn: Machine Learning
  - scipy: Phân tích thống kê

5. ĐƠN VỊ PHÂN TÍCH VÀ PHẠM VI DỰ BÁO

- **Đơn vị phân tích (Unit of Analysis):** Một bản ghi (record) trong tập dữ liệu huấn luyện đại diện cho hành vi của một sinh viên U_i trong một khoảng thời gian cụ thể (tuần W_t).
- **Phạm vi dự báo (Prediction Scope):** Áp dụng cách tiếp cận chuỗi thời gian (Time-series sliding window). Hệ thống sử dụng vector đặc trưng của tuần t để dự báo nhãn tương tác của tuần t+1. Chiến lược này đảm bảo tính "Cảnh báo sớm", cung cấp cho giảng viên khoảng thời gian đệm để can thiệp trước khi sinh viên thực sự rời bỏ khóa học (dropout).

6. CHIẾN LƯỢC GÁN NHÃN

Khắc phục nhược điểm của các phương pháp đánh giá chủ quan, chiến lược gán nhãn Ground Truth được thực hiện hoàn toàn tự động bằng thuật toán học không giám sát:

i. **Chuẩn hóa dữ liệu:** Vector đặc trưng (tổng hợp từ video, bài tập, diễn đàn) được chuẩn hóa bằng StandardScaler (Z-score) để loại bỏ sự chênh lệch về thang đo giữa các thuộc tính.

ii. **Xác định số cụm (k):** Áp dụng phương pháp Elbow (đánh giá mức độ suy giảm của Inertia) để chốt k=3.

iii. **Phân cụm K-Means:** Phân chia không gian vector theo khoảng cách Euclidean.

iv. **Mapping nhãn:** Tính toán tọa độ trọng tâm (Centroids) của 3 cụm. Cụm có giá trị trung bình các đặc trưng tương tác cao nhất được gán nhãn **High**, trung bình gán **Medium**, thấp nhất gán **Low**.

7. QUY TRÌNH THỰC NGHIỆM

Giai đoạn 1: Định hình và trích xuất đặc trưng chuỗi thời gian: Time-Series

Hành vi học tập không phải là một điểm tĩnh mà là một quá trình. Việc trích xuất đặc trưng theo chuỗi thời gian là chìa khóa để xây dựng hệ thống cảnh báo sớm.

i. **Time Windowing:**

a. Thay vì cộng gộp toàn bộ dữ liệu của khóa học, log hành vi của 5.000 sinh viên sẽ được cắt lát theo từng tuần học (Ví dụ: Tuần 1, Tuần 2,..., Tuần N).

b. Cấu trúc dữ liệu dạng Panel: Mỗi dòng dữ liệu đại diện cho hành vi của sinh viên i tại tuần t.

ii. **Tạo các tập đặc trưng theo thời gian:**

a. **Đặc trưng tĩnh:** Giới tính, năm sinh, trường học, độ dài khóa học đã đăng ký.

b. **Đặc trưng động lũy kế:** Tổng thời lượng xem video (watch_time) từ đầu khóa học đến tuần t, tổng số bài tập đã nộp, tổng số comment/reply.

c. **Đặc trưng xu hướng:** Đây là yếu tố quan trọng nhất. Tính toán sự thay đổi (delta) giữa tuần t và tuần t-1. Ví dụ: delta_attempts , delta_activity Delta_watch_time_W2_W1 = Thời lượng xem video tuần 2 trừ đi tuần 1. Giá trị âm liên tiếp là tín hiệu dự báo sự sụt giảm tương tác.

d. **Đặc trưng nhịp độ (Pacing Features):** Khoảng cách thời gian trung bình giữa các lần đăng nhập hoặc giữa các lần nộp bài: login, submit.

e. **Weighted Engagement Score (WES):** phản ánh mức độ quan trọng của từng hành vi:

$$E_i = \sum_{\alpha \in A} \sum_{\omega=1}^{N} x_{i,\alpha,\omega} \cdot \omega_\alpha$$

Trong đó:

$$\omega_\alpha = \frac{\sum_{i=1}^{S} \sum_{\omega=1}^{N} x_{i,\alpha,\omega}}{S \times N}$$

Giai đoạn 2: Khởi tạo nhãn chuẩn (Ground Truth) bằng K-Means

Vì dữ liệu ban đầu chưa có nhãn "High", "Medium", "Low", thuật toán K-Means sẽ đảm nhiệm việc này một cách khách quan dựa trên khoảng cách vector đặc trưng.

i. **Chuẩn hóa dữ liệu:** Áp dụng **Z-score Normalization** (StandardScaler) cho toàn bộ các đặc trưng số để thuật toán không bị chệch hướng bởi các biến có thang đo lớn (như watch_time).

ii. **Tối ưu hóa số cụm (k):**

   a. Sử dụng phương pháp **Elbow** kết hợp với đồ thị **Silhouette Score** để xác nhận k = 3 là cấu trúc phân cụm tối ưu nhất.

iii. **Đánh giá chất lượng cụm (Cluster Validation):**

   a. *Within-Cluster Sum of Square (WSS)* và *Between-Cluster Sum of Square (BSS)* để đảm bảo các cụm nén chặt bên trong và cách xa nhau.

   b. Sử dụng chỉ số **Davies-Bouldin Index**:Điểm càng thấp, cụm càng phân biệt rõ ràng.

iv. **Gán nhãn Logic:** Dựa vào giá trị trung bình (Centroids) của các cụm đối với các tính năng cốt lõi (như watch_time, score, attempts), thuật toán gán nhãn:

   a. Cụm có Centroid cao nhất -> **High (Tương tác cao)** (Tỷ lệ hiện tại ~48%)

   b. Cụm có Centroid thấp nhất -> **Low (Tương tác thấp)** (Tỷ lệ hiện tại ~35%)

   c. Cụm còn lại -> **Medium (Tương tác trung bình)** (Tỷ lệ hiện tại ~18%)

Giai đoạn 3: Phân chia tập dữ liệu và Xử lý mất cân bằng (SMOTE)

Để tránh Data Leakage, lỗi phổ biến nhất khiến mô hình đạt điểm cao ảo khi training nhưng dự đoán thực tế kém - quy trình SMOTE phải được thực hiện cực kỳ cẩn trọng.

i. **Stratified Split:** Khi phân chia dữ liệu, phương pháp lấy mẫu ngẫu nhiên tiềm ẩn rủi ro rất lớn đối với dữ liệu mất cân bằng. Nếu chia ngẫu nhiên, tập test có thể tình cờ không chứa hoặc chứa rất ít mẫu của lớp Medium (nhóm thiểu số chiếm 1.8 phần), dẫn đến việc các độ đo đánh giá bị sai lệch và không đại diện cho thực tế. Kỹ thuật Stratified Split giải quyết triệt để vấn đề này bằng cách ép buộc cấu trúc phân phối lớp gốc phải được sao chép chính xác vào các tập con. Dữ liệu mẫu đã gán nhãn chia thành tập train, validation và test theo tỷ lệ **80:10:10**.

ii. **Áp dụng SMOTE (Synthetic Minority Over-sampling Technique):**

   a. **Chỉ áp dụng kỹ thuật SMOTE trên tập train.** Thuật toán sẽ nội suy tạo ra các điểm dữ liệu nhân tạo cho nhóm Medium và Low để cân bằng số lượng với nhóm High, ép tỷ lệ phân bổ từ **4.8:1.8:3.5** về trạng thái cân bằng **1:1:1** trước khi đưa vào huấn luyện mô hình phân lớp.
   b. Tập test hoàn toàn không sử dụng SMOTE, giữ nguyên trạng thái bất đối xứng thực tế để phản ánh đúng hiệu suất khi triển khai thực tiễn. Khi Confusion Matrix và chỉ số Recall được tính toán trên tỉ lệ mẫu này, kết quả sẽ phản ánh chính xác xác suất hệ thống bỏ sót sinh viên Low trong môi trường giáo dục thực tế.

Giai đoạn 4: Huấn luyện và tối ưu mô hình (Supervised Learning)

Thực nghiệm sẽ được chạy qua 4 thuật toán, kết hợp với phương pháp kiểm chứng chéo **Stratified 5-Fold Cross-Validation** trên tập Train để đảm bảo tính ổn định.

Mô hình	**Kỹ thuật tối ưu siêu tham số (Hyperparameter Tuning)**	**Cấu hình dự kiến (GridSearchCV / Optuna)**
Logistic Regression (Baseline)	Hiệu chuẩn hình phạt (Penalty Tuning)	C (Độ mạnh regularization), penalty (L1, L2).
Random Forest	Tối ưu cấu trúc cây tập hợp	n_estimators (số lượng cây), max_depth (độ sâu tối đa), min_samples_split.
XGBoost	Tối ưu gradient và học sâu	learning_rate (tốc độ học), max_depth, subsample, gamma (ngăn overfitting).
CatBoost	Tối ưu chuyên biệt cho biến Categorical	iterations, learning_rate, depth, tự động kích hoạt auto_class_weights='Balanced'.

Giai đoạn 5: Hệ thống tiêu chuẩn đánh giá (Evaluation Metrics)

Với bài toán Multi-class Classification và dữ liệu có sự chênh lệch nhãn gốc, độ chính xác tổng thể không phải là thước đo đáng tin cậy nhất. Kịch bản thực nghiệm sẽ sử dụng các độ đo sau trên tập test:

i. **Confusion Matrix:** Quan sát trực quan số lượng sinh viên bị dự đoán sai từ Low lên High.

ii. **F1-Score:**

- *Macro F1:* Trung bình cộng F1 của 3 nhãn, xử lý công bằng cả lớp Medium dù số lượng ít.
- *Weighted F1:* Trung bình F1 có tính đến trọng số tương đương với số lượng mẫu của từng nhãn.

iii. **Precision - Recall:** Đặc biệt chú trọng vào độ đo Recall của lớp Low. Trong ngữ cảnh giáo dục, ưu tiên cảnh báo nhầm một sinh viên bình thường - False Positive còn hơn là bỏ sót một sinh viên đang sắp bỏ học - False Negative.

iv. **ROC-AUC (One-vs-Rest):** Đo lường khả năng phân tách của mô hình giữa một lớp bất kỳ với các lớp còn lại. AUC > 0.85 được xem là mô hình có tính ứng dụng cao.

v. **Feature Importance:** Trích xuất từ cây quyết định của XGBoost/CatBoost để xác định Top 5 đặc trưng có tính quyết định nhất, làm cơ sở khoa học để thiết kế các chỉ số trên màn hình Dashboard cảnh báo.

Giai đoạn 6: Khả năng giải thích mô hình: Model Interpretability

i. **Mục tiêu của giai đoạn**

Trong khai phá dữ liệu giáo dục (EDM), một mô hình có độ chính xác 99% nhưng hoạt động như một black-box sẽ bị loại bỏ khi triển khai. Giảng viên cần biết tại sao hệ thống đưa ra cảnh báo để có phương án sư phạm phù hợp. Ví dụ: Sinh viên rớt nhóm Low do không xem video hay do làm bài tập điểm kém? Giai đoạn này chuyển đổi kết quả toán học thành tri thức nghiệp vụ.

ii. **Kỹ thuật thực hiện chi tiết**

Áp dụng hai cấp độ giải thích từ tổng quát đến cục bộ:

a. **Trích xuất độ quan trọng của đặc trưng (Global Interpretability - Feature Importance):**

- **Kỹ thuật:** Sử dụng chỉ số Gini Impurity giảm dần (Mean Decrease in Impurity) hoặc chỉ số Information Gain được cung cấp sẵn từ các mô hình dạng cây (Random Forest, XGBoost).
- **Thực thi:** Trích xuất vector trọng số của toàn bộ đặc trưng, sắp xếp giảm dần để tìm ra Top 5 hoặc Top 10 biến số chi phối mạnh nhất đến kết quả mô hình. Ví dụ: Phát hiện ra delta_watch_time (sự sụt giảm thời gian xem so với tuần trước) là tín hiệu mạnh nhất. Kết quả này được dùng làm tham số cứng để vẽ các biểu đồ cảnh báo trên màn hình Dashboard.

b. **Giá trị SHAP (Local & Global Interpretability):**

- **Toán học:** Áp dụng lý thuyết trò chơi hợp tác - Cooperative Game Theory để tính toán Shapley Values. Mỗi đặc trưng được xem là một người chơi đóng góp vào phần thưởng - xác suất dự báo nhãn.
- **Kỹ thuật thực thi:** Sử dụng thư viện shap trong Python, kỹ thuật TreeExplainer tối ưu cho Boosting.
- **Phân tích cục bộ:** Force Plot của SHAP cho phép giải thích chi tiết một sinh viên cụ thể. Mũi tên đỏ đẩy xác suất về nhóm Low. Ví dụ: Sinh viên này không nộp bài 2 ngày liên tiếp, mũi tên xanh đẩy xác suất về nhóm High - điểm bài trước rất cao. Giảng viên nhìn vào biểu đồ này sẽ ngay lập tức có kịch bản trao đổi chính xác với sinh viên.