THUYẾT MINH ĐỀ TÀI

A. THÔNG TIN TỔNG QUAN

A.1 Tên đề tài:

- **Tên đề tài tiếng Việt:** Phân tích dữ liệu hành vi học tập đa nguồn trên hệ thống MOOC (MOOCCubeX): Phân cụm và dự đoán mức độ tương tác dựa trên thuật toán K-Means và Mô hình học có giám sát.
- **Tên tiếng Anh:** Multi-Source Educational Data Mining - Predicting and Classifying Learner Engagement Levels (High, Medium, Low) in the MOOCCubeX Ecosystem.

A.2 Lĩnh vực ứng dụng, triển khai, nghiên cứu

Khoa học dữ liệu (Data Science) và Khai phá dữ liệu giáo dục (Educational Data Mining - EDM) - Lĩnh vực Công nghệ thông tin / Khoa học máy tính.

A.3 Thành viên thực hiện và Phân công công việc

STT	Thành viên	Vai trò	Nội dung thực hiện
1		Trưởng nhóm	Nội dung 1.
2		Phó nhóm	Nội dung 2.
3		Thành viên	Nội dung 3.
4		Thành viên	Nội dung 4.
5		Thành viên	Nội dung 5.

B. MÔ TẢ NGHIÊN CỨU

B1. Giới thiệu về đề tài

B1.1 Ý tưởng khoa học, tính cấp thiết và tính mới

- **Tính cấp thiết:** Việc thiếu tương tác trực tiếp trên các nền tảng MOOC dẫn đến tỷ lệ bỏ học (dropout rate) rất cao. Cần thiết phải có một hệ thống khai phá dữ liệu khai thác chuỗi log thời gian thực để chẩn đoán sớm và cảnh báo kịp thời nhóm sinh viên đang mất động lực học tập.
- **Định nghĩa Bài toán / Vấn đề nghiên cứu:**

- *Ngữ cảnh - Ứng dụng:* Khai phá dữ liệu giáo dục (EDM) nhằm hỗ trợ giảng viên và ban quản trị nền tảng MOOC.
- *Đầu vào (Input):* Chuỗi dữ liệu lịch sử hoạt động (video log, quá trình làm bài) và đặc trưng định danh của sinh viên.
- *Đầu ra (Output):* Dự báo phân lớp đa lớp (Multiclass Classification) gồm 3 nhãn: Tương tác Cao (High), Trung bình (Moderate), và Thấp (Low).

- **Tính mới:** Thay vì đánh giá mức độ tương tác bằng các ngưỡng điểm tĩnh, đề tài sử dụng một quy trình gồm 5 thuật toán. Thuật toán **K-Means (Học không giám sát)** giải quyết bài toán dữ liệu thưa bằng cách gom cụm hành vi theo khoảng cách Euclidean trên dữ liệu chuẩn hóa Z-score. Các cụm tự nhiên này trở thành nhãn mục tiêu để huấn luyện 4 thuật toán Học có giám sát (**Logistic Regression, Random Forest, XGBoost, CatBoost**). Cách tiếp cận này loại bỏ hoàn toàn định kiến chủ quan của con người trong việc xác định thế nào là "tương tác cao hay thấp", đồng thời tối ưu hóa tốc độ dự báo đối với dữ liệu phát sinh mới.

B1.2 Tổng quan tình hình nghiên cứu

Sự phát triển mạnh mẽ của các nền tảng học trực tuyến mở đại trà (MOOC) tạo ra khối lượng dữ liệu khổng lồ, mở ra cơ hội định lượng hành vi học tập của sinh viên. Mức độ tham gia (engagement) thường được quan sát thông qua các dấu vết kỹ thuật số như tần suất đăng nhập, thời gian tương tác và tỷ lệ hoàn thành bài tập. Tuy nhiên, các phương pháp đánh giá truyền thống chủ yếu dựa vào dữ liệu tự báo cáo hoặc kết quả cuối kỳ, làm mất đi khả năng can thiệp theo thời gian thực. Phần lớn các nghiên cứu hiện tại áp dụng học có giám sát (Supervised Learning) trên các bộ dữ liệu đã được gán nhãn chủ quan. Đề tài này lấp đầy khoảng trống đó bằng việc triển khai kiến trúc học máy lai (Hybrid Machine Learning Architecture): tận dụng K-Means Clustering để tự động khám phá và thiết lập nhãn chuẩn (ground-truth) khách quan theo từng tuần, làm tiền đề để huấn luyện các thuật toán phân lớp tiên tiến trên bộ dữ liệu MOOCCubeX.

B1.3 Kết quả nghiên cứu sơ khởi

Đến nay, nhóm nghiên cứu đã hoàn thành xuất sắc Giai đoạn 1 (Tích hợp và Tiền xử lý dữ liệu). Nguồn dữ liệu từ 5 tập tin dị thể của hệ thống MOOCCubeX (bao gồm user, user-video, user-problem, comment, reply) với hơn 4,4 triệu bản ghi log thô đã được làm phẳng (flattening) các chuỗi JSON và hợp nhất thông qua khóa user_id.

Kết quả thu được là một bộ dữ liệu (Dataset) chất lượng cao, cô đọng lại thành **5.000 samples (mẫu)** đại diện cho 5.000 học viên với đầy đủ các vector đặc trưng hành

vi. Bước đầu áp dụng gán nhãn, tập dữ liệu cho thấy tỷ lệ phân bổ nhãn giữa 3 lớp tương tác (Cao : Trung bình : Thấp) là **4.8 : 1.8 : 3.5**. Kết quả sơ khởi này bộc lộ rõ tình trạng mất cân bằng lớp (class imbalance) trong hành vi học tập thực tế, tạo cơ sở dữ liệu vững chắc để nhóm tiếp tục áp dụng kỹ thuật SMOTE và đưa vào huấn luyện các mô hình phân lớp nâng cao trong các giai đoạn tiếp theo.

B2. Mục tiêu, nội dung, kế hoạch nghiên cứu

B2.1 Mục tiêu

- Giải quyết triệt để bài toán làm phẳng (flattening) các cấu trúc dữ liệu JSON đa cấp trong chuỗi log hành vi học tập của hệ thống MOOC.
- Triển khai thuật toán K-Means Clustering phân chia người học thành 3 cụm tương tác một cách khách quan dựa trên đặc trưng chuỗi thời gian.
- Tối ưu hóa siêu tham số (Hyperparameter tuning) cho 4 mô hình học có giám sát để tìm ra kiến trúc dự báo chính xác nhất, phục vụ hệ thống cảnh báo sớm.

B2.2 Nội dung và phương pháp nghiên cứu

- **Nội dung 1: Hợp nhất và Tiền xử lý dữ liệu đa nguồn**
    - *Mục tiêu:* Tích hợp 5 tập dữ liệu dị thể thành một không gian dữ liệu đồng nhất.
    - *Phương pháp thực hiện:* Triển khai các phép nối dữ liệu (Join) trên khóa *user_id*. Áp dụng các kỹ thuật xử lý chuỗi JSON trong trường *seq* để trích xuất *watch_time*. Xử lý giá trị khuyết thiếu (Imputation) thông qua mean/median hoặc gán hằng số (constant). Áp dụng Data Leakage Prevention ngay từ khâu đầu tiên.
    - *Sản phẩm dự kiến:* Tập Master Dataset hoàn chỉnh, sạch và không chứa nhiễu.
- **Nội dung 2: Phân tích khám phá dữ liệu (EDA) chuyên sâu**
    - *Mục tiêu:* Tìm ra các quy luật ẩn (insights) và đánh giá sự phân phối của dữ liệu gốc.

- *Phương pháp thực hiện:* Thực hiện thống kê mô tả (Descriptive Statistics); kiểm định giả thuyết. Sử dụng Ma trận tương quan (Heatmap Correlation Matrix) để phân tích mối quan hệ giữa các hoạt động học tập (ví dụ: tương quan thuận giữa total_watch_time và score).
- *Sản phẩm dự kiến:* Báo cáo EDA tổng hợp và hệ thống biểu đồ trực quan hóa dữ liệu gốc.

- **Nội dung 3: Kỹ thuật đặc trưng và Phân cụm gán nhãn bằng K-Means**
  - *Mục tiêu:* Biến đổi log dữ liệu thành vector đặc trưng theo tuần và sử dụng Học không giám sát để thiết lập nhãn chuẩn (Ground Truth).
  - *Phương pháp thực hiện:* Trích xuất các biến tổng hợp như *video_watch_count*, tỷ lệ nộp bài, thời lượng tương tác. Áp dụng Z-score normalization để chuẩn hóa không gian vector, đảm bảo mọi đặc trưng có trung bình 0 và phương sai 1. Chạy thuật toán K-Means sử dụng khoảng cách Euclidean. Xác định k = 3 bằng phương pháp Elbow. Đánh giá chất lượng cụm thông qua hệ số Silhouette, WSS và BSS, sau đó gán nhãn: High, Moderate, Low.
  - *Sản phẩm dự kiến:* Tập dữ liệu Vector đặc trưng đã được gán nhãn 3 lớp hoàn chỉnh.

- **Nội dung 4: Xây dựng và đánh giá Mô hình dự báo phân loại đa lớp**
  - *Mục tiêu:* Huấn luyện các mô hình Học có giám sát để dự đoán mức độ tương tác dựa trên nhãn đã được K-Means khởi tạo.
  - *Phương pháp thực hiện:* Giải quyết vấn đề mất cân bằng mẫu (tỷ lệ 4.8:1.8:3.5) bằng kỹ thuật lấy mẫu tổng hợp SMOTE. Khởi chạy 4 thuật toán:
    1. *Logistic Regression:* Đóng vai trò mô hình cơ sở (Baseline model).
    2. *Random Forest:* Giải quyết overfitting, xử lý tốt ngoại lệ (outliers) thông qua cấu trúc cây tập hợp (Bagging).
    3. *XGBoost:* Tối ưu hóa gradient (Boosting) cho hiệu năng tốc độ tính toán cao.
    4. *CatBoost:* Khai thác sức mạnh xử lý dữ liệu hạng mục (Categorical) mã trường, mã khóa học mà không cần One-hot encoding. Sử dụng

kỹ thuật SMOTE để xử lý mất cân bằng nhãn. Đánh giá mô hình qua Accuracy, Precision, Recall và F1-Score.

- *Danh sách thuật toán dự kiến thực nghiệm:*

Thuật Toán	**Loại Mô Hình**	**Đặc Điểm Cốt Lõi**
K-Means Clustering	Học không giám sát (Clustering)	Phân cụm dữ liệu dựa trên khoảng cách Euclidean, tự động nhóm 5.000 sinh viên thành 3 cụm hành vi tự nhiên (tạo nhãn Ground Truth).
Logistic Regression	Tuyến tính (Supervised)	Đơn giản, tính toán nhanh, giải thích rõ ràng trọng số của từng loại hành vi thông qua hệ số hồi quy.
Random Forest	Tập hợp (Ensemble / Bagging)	Kết hợp nhiều cây quyết định, giảm overfitting, tính ổn định cao, xử lý tốt ngoại lệ (outliers).
XGBoost	Tập hợp (Ensemble / Boosting)	Tối ưu hóa gradient boosting, tốc độ cực nhanh, hỗ trợ tốt dữ liệu khuyết thiếu và tương thích mạnh với SMOTE.
CatBoost	Tập hợp (Ensemble / Boosting)	Chuyên trị dữ liệu dạng phân loại (Categorical) như mã trường, mã khóa học mà không cần One-hot encoding thủ công.

- *Đánh Giá Chi Tiết Từng Thuật Toán (Mô hình có giám sát):*

Thuật toán	**Hiệu quả dự kiến**	**Tốc độ**	**Ưu điểm nổi bật**	**Nhược điểm**
Logistic Regression	Trung bình (Giả định quan hệ tuyến tính)	Rất nhanh	- Đóng vai trò làm Baseline tham chiếu tuyệt vời.	- Bỏ lỡ các quy luật phức tạp và phi tuyến tính trong chuỗi dữ liệu log của sinh viên.

			- Dễ giải thích được tác động của từng hành vi lên kết quả.	
Random Forest	Tốt và Ổn định	Trung bình	- Không cần chuẩn hóa dữ liệu quá khắt khe. - Tự động tính toán Feature Importance tốt.	- Cồng kềnh, tốn bộ nhớ nếu số lượng cây quyết định quá lớn. - Kém nhạy bén với sự chênh lệch nhãn 4.8:1.8:3.5 nếu không xử lý kỹ.
XGBoost	Rất cao	Nhanh	- Tối ưu hóa tối đa quy luật dữ liệu dạng bảng. - Hỗ trợ mạnh mẽ việc gán trọng số lớp (scale_pos_weight) để trị mất cân bằng.	- Cần tinh chỉnh siêu tham số (Hyperparameter tuning) cẩn thận. - Bắt buộc phải mã hóa dữ liệu chữ sang số hoàn toàn.
CatBoost	**Cực kỳ ấn tượng**	Tốc độ Inference rất nhanh	- Xử lý trực tiếp biến phân loại (Categorical) cực mạnh. - Tích hợp sẵn cơ chế cân bằng lớp (auto_class_weights).	- File mô hình lưu trữ nặng hơn. - Thời gian huấn luyện ban đầu tốn kém nếu không có GPU hỗ trợ.

- *Sản phẩm dự kiến:* Bảng so sánh ma trận nhầm lẫn (Confusion Matrix) và mô hình phân loại dự báo tối ưu nhất.

- **Nội dung 5: Đánh giá hiệu quả ứng dụng và Trực quan hóa**
    - *Mục tiêu:* Chuyển đổi kết quả phân tích kỹ thuật thành công cụ quản trị thực tiễn.
    - *Phương pháp thực hiện:* Trích xuất Feature Importance từ thuật toán Ensemble mạnh nhất (CatBoost hoặc XGBoost) để xác định hành vi mang tính quyết định đến sự sụt giảm tương tác. Xây dựng Dashboard (Power BI hoặc Python Dash) mô tả sự chuyển dịch cụm (cluster transitions) theo từng tuần học.
    - *Sản phẩm dự kiến:* Hệ thống Dashboard cung cấp cảnh báo sớm (Early Warning System) cho giảng viên.

B2.3 Kế hoạch nghiên cứu

Thời gian	**Nội dung thực hiện**
Tháng 1	**(Đã hoàn thành phần lớn Nội dung 1)** Hoàn thiện Phân tích EDA chuyên sâu (Nội dung 2) trên tập dữ liệu 5.000 mẫu.
Tháng 2	**Thực hiện Nội dung 3:** Kỹ thuật đặc trưng, chuẩn hóa dữ liệu, chạy thuật toán K-Means và hoàn tất việc gán nhãn 3 lớp.
Tháng 3	**Thực hiện Nội dung 4:** Áp dụng SMOTE cân bằng tỷ lệ 4.8:1.8:3.5, tinh chỉnh siêu tham số và huấn luyện 4 mô hình phân lớp có giám sát. Đánh giá hiệu năng.
Tháng 4	**Thực hiện Nội dung 5:** Trích xuất Feature Importance, thiết kế Dashboard, đóng gói mã nguồn và viết báo cáo khoa học.

B3. Kết quả dự kiến

- **Bản báo cáo khoa học:** Chuyên đề "Ứng dụng kiến trúc lai kết hợp K-Means Clustering và Machine Learning trong định lượng và dự báo mức độ tương tác của sinh viên hệ thống MOOC".
- **Bộ mã nguồn (Source Code):** Script Python tích hợp luồng xử lý tự động (Data Pipeline) từ tiền xử lý dữ liệu thô đến dự đoán inference.

- **Tập dữ liệu (Datasets):** Bộ dữ liệu MOOCCubeX tinh gọn gồm 5.000 samples đã được xử lý cân bằng mẫu và gán nhãn.
- **Hệ thống Dashboard:** Hệ thống cảnh báo sinh viên nguy cơ cao, tích hợp chức năng theo dõi diễn biến hành vi theo chuỗi thời gian.

B4. Tài liệu tham khảo

1. Alzahrani, N., Meccawy, M., Samra, H., & El-Sabagh, H. A. (2025). Identifying Weekly Student Engagement Patterns in E-Learning via K-Means Clustering and Label-Based Validation. *Electronics*, 14, 3018.
2. Nền tảng dữ liệu mở MOOCCubeX (Tài liệu đặc tả kiến trúc dữ liệu hành vi và quan hệ thực thể).